

Tóm tắt bài giảng: Support Vector Machine (SVM)

Tháng 12 năm 2025

1 Ý nghĩa và mục tiêu của SVM

Support Vector Machine (SVM) là một mô hình học máy mạnh mẽ, chủ yếu được sử dụng cho các bài toán phân loại (Classification).

Trong không gian dữ liệu, có thể tồn tại vô số siêu phẳng có khả năng phân tách các lớp. SVM giải quyết vấn đề này bằng cách xác định **siêu phẳng tối ưu** (Optimal Hyperplane) — mặt phẳng có khoảng cách lớn nhất tới các điểm dữ liệu gần nhất của các lớp.

- **Support Vectors:** Là những điểm dữ liệu nằm sát siêu phẳng nhất. Chúng đóng vai trò quyết định vị trí của siêu phẳng.
- **Margin (Biên độ):** Khoảng cách từ siêu phẳng đến các Support Vectors. SVM đặt mục tiêu tối đa hóa khoảng cách này (*Maximize Margin*).

Việc tối đa hóa margin mang lại các lợi ích:

- **Ranh giới quyết định an toàn hơn trước nhiễu:** Tránh việc các điểm nhiễu làm thay đổi ranh giới quá mức.
- **Giảm rủi ro Overfitting (quá khớp):** Mô hình không bị quá phụ thuộc vào các điểm dữ liệu cá biệt.
- **Nâng cao khả năng tổng quát hóa:** Mô hình hoạt động ổn định hơn trên dữ liệu mới chưa từng thấy.

2 SVM trong mã nguồn và công thức toán học

2.1 Functional Margin

Được định nghĩa để đánh giá độ chính xác và độ tin cậy của dự đoán:

$$\text{Functional Margin} = y_i(w^T x_i + b)$$

Trong đó $(w^T x + b)$ là *score* (điểm số) của mô hình:

- Nếu $\text{Margin} > 0$: Dự đoán đúng (nhãn thực y và score cùng dấu).
- Nếu $\text{Margin} < 0$: Dự đoán sai.

2.2 Hinge Loss

Hàm mất mát đặc trưng của SVM giúp mô hình không chỉ phân loại đúng mà còn phải đúng với một khoảng cách an toàn:

$$\mathcal{L}_{\text{Hinge}} = \max(0, 1 - y(w^T x + b))$$




Figure 1: So sánh các siêu phẳng: Đường đỏ là siêu phẳng tối ưu giúp tối đa hóa biên độ (margin) tới các điểm dữ liệu gần nhất, trong khi các đường xanh và tím dẫn đến phân loại sai.

2.3 Regularization và Hàm mất mát tổng

Hàm mất mát tổng thể được tối ưu hóa:

$$Loss = \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \max(0, 1 - y_i(w^T x_i + b))$$

Tham số C điều chỉnh sự cân bằng:

- **C lớn:** Ưu tiên phân loại đúng tuyệt đối, chấp nhận margin hẹp.
- **C nhỏ:** Ưu tiên margin rộng, chấp nhận một số sai lệch nhỏ để tăng tính tổng quát.

3 Kernel Trick và Các loại Kernel

Kernel Trick cho phép SVM phân tách dữ liệu phi tuyến bằng cách ánh xạ chúng vào không gian cao chiều hơn mà không cần tính toán trực tiếp tọa độ phức tạp. Các loại Kernel phổ biến:

- **Linear (Tuyến tính):** Dùng cho dữ liệu có thể phân tách bằng đường thẳng.
- **Polynomial (Đa thức):** Mô hình hóa các ranh giới phức tạp dạng đường cong đa thức.
- **RBF (Radial Basis Function):** Kernel mặc định và mạnh mẽ nhất, có khả năng xử lý hầu hết các dạng dữ liệu phi tuyến.

4 Mở rộng SVM cho Bài toán Đa lớp

1. One-vs-One (OvO): Đấu tay đôi & Bỏ phiếu

- **Cơ chế:** Chia các lớp thành từng cặp đối đầu trực tiếp. Với N (ví dụ $N=3$) lớp, huấn luyện $\frac{N(N-1)}{2}$ (số mô hình = 3) mô hình.
- **Quyết định:** Đếm tổng số phiếu bầu từ các cặp đấu, lớp nào nhiều phiếu nhất sẽ thắng.
- **Ví dụ:** Với 3 lớp (A, B, C):
 - SVM 1 (A vs B) → chọn B; SVM 2 (A vs C) → chọn A; SVM 3 (B vs C) → chọn B.
 - **Kết quả:** B (2 phiếu) > A (1 phiếu) → **Chốt Lớp B.**

2. One-vs-Rest (OvR): Một đối với Tất cả

Mỗi lớp được huấn luyện để tự phân biệt mình với toàn bộ các lớp còn lại cộng lại.

- **Cơ chế:** Tạo N mô hình tương ứng với N lớp (ví dụ: A vs Không phải A, B vs Không phải B...).
- **Dự đoán:** Mỗi mô hình trả về một điểm số tin cậy (Confidence Score) cho lớp đó.
- **Quyết định:** Lớp nào có **điểm số cao nhất** sẽ được chọn làm kết quả cuối cùng.
- **Ví dụ:**
 - Điểm của mô hình A = 0.2.
 - Điểm của mô hình B = 0.8.
 - Điểm của mô hình C = 0.1.
- **Kết quả:** B cao nhất (0.8) → **Chốt Lớp B**.

5 Kết luận

SVM không chỉ tìm cách phân loại đúng mà còn đặt ranh giới tại vị trí **an toàn nhất**, đảm bảo hiệu quả bền vững cho mô hình.